

卒 業 論 文

サイズ制約つき極小ヒットティングセット列挙における
最大集合パッキング下界枝刈りの有効性評価

102210211 藤井亜門

名古屋大学大学院情報科学研究科

数理情報学専攻

2026年2月

サイズ制約つき極小ヒッティングセット列挙における 最大集合パッキング下界枝刈りの有効性評価

102210211 藤井 亜門

概要

サイズ制約付き極小ヒッティングセット (minimal hitting set: MHS) の列挙はデータマイニングにおける頻出パターン抽出や、システム障害診断における原因特定など、多岐にわたる分野で重要な応用を持つ計算課題である。しかし、MHS の探索空間は膨大であり効率的な列挙アルゴリズムの実現には探索の無駄を省く効率的な枝刈り手法が必要とされている。本研究では最小ヒッティングセット問題の双対問題である最大セットパッキング (max set packing: MaxSP) に着目し、その解サイズを下界として利用した分枝限定法の性能を評価した。実験からは以下の2点の知見が得られた。

第一に、MaxSP 下界の有効性はハイパーグラフの構造に強く依存する傾向が確認された。疎なグラフや極めてランク（エッジ集合のもつ要素の数の最大値）が高いグラフにおいては MaxSP 下界を用いた探索ノード数が理論値と一致し、高精度で枝刈りが機能することを確認した。対照的に、中程度のランクを持つ競合密度の高いグラフにおいては理論値との乖離が拡大し、MaxSP による下界評価の限界が示された。

第二に、MaxSP の計算に高速な貪欲法を用いた場合と計算コストのかかる厳密解法を用いた場合の間で探索ノード数に大きな差は見られなかった。この事実は、探索効率のボトルネックが近似アルゴリズムの精度不足にあるのではなく MaxSP 緩和が持つ数理的な限界、すなわち双対ギャップにあることを示唆している。

本研究の結果は MaxSP の近似精度向上よりも双対ギャップを低減させる緩和手法の導入の方が有効であるという指針を与えるものである。

目次

第 1 章	はじめに	1
1.1	背景と動機	1
1.2	課題	1
1.3	本研究の目的	2
1.4	論文の構成	2
第 2 章	問題定義	3
2.1	基本記号とハイパーグラフ	3
2.1.1	ハイパーグラフの定義	3
2.2	ヒッティングセット問題 (Hitting Set Problems)	3
2.2.1	ヒッティングセットの定義	3
2.2.2	極小ヒッティングセットの定義	3
2.2.3	最小ヒッティングセット問題	4
2.2.4	サイズ制約付き極小ヒッティングセット列挙	4
2.3	セットパッキング問題 (Set Packing Problems)	4
2.3.1	セットパッキングの定義	4
2.3.2	最大セットパッキング問題	4
2.3.3	競合グラフによる定式化	4
2.4	双対関係と下界	5
2.4.1	弱双対定理	5
第 3 章	定式化	6
3.1	整数計画法による定式化	6
3.1.1	MinHS の IP 定式化	6
3.1.2	MaxSP の IP 定式化	6
3.2	枝刈り条件の導出	7
3.3	極小性の必要十分条件	7
第 4 章	比較手法	8
4.1	アルゴリズムの全体枠組み	8
4.2	下界計算戦略と疑似コード	9
4.2.1	Greedy MaxSP (貪欲法)	9
4.2.2	Exact MaxSP (厳密解法)	10
4.2.3	Oracle MinHS	10
4.3	極小性判定の実装	10
4.4	計算量解析	11

第 5 章 計算実験	12
5.1 実験環境	12
5.2 評価指標	12
5.3 構造指標の導入	12
5.4 実験結果	13
5.5 実験 1. 射影平面グラフ (Projective)	13
5.5.1 概要	13
5.5.2 結果	13
5.6 実験 2. 2 部グラフ (Bipartite)	14
5.6.1 概要	14
5.6.2 結果	14
5.7 実験 3 実データとその補集合データ (Actual)	14
5.7.1 概要	14
5.7.2 結果	15
5.8 実験 4. ランダムグラフにおけるランク分散と競合密度の影響	15
5.8.1 実験の目的と設計	15
5.8.2 ランクと探索オーバーヘッドの関係	16
5.8.3 競合密度の影響	17
5.9 カテゴリ別検証のまとめ	17
第 6 章 考察とまとめ	18
6.1 実験結果の考察	18
6.1.1 近似ギャップの影響と貪欲法の有効性	18
6.1.2 グラフ構造と双対ギャップの関係	18
6.2 結論	19
6.3 今後の展望	19
参考文献	21

第1章 はじめに

1.1 背景と動機

近年, データマイニングやネットワーク解析などの多様な分野において, 離散構造の列挙問題が重要な役割を果たしている. 特に, トランザクションデータからの頻出アイテムセット抽出や, システム障害における極小故障集合の特定など, 多くの実問題が「極小ヒッティングセット (Minimal Hitting Set: MHS) 列挙問題」として定式化される [8].

ヒッティングセット問題とは, 与えられたハイパーグラフ $H = (V, E)$ に対して, すべてのエッジ $e \in E$ と少なくとも 1 つの共通頂点を持つ頂点集合 $S \subseteq V$ を求める問題である. その中でも, 包含関係に関して極小な (これ以上頂点を除去できない) ものを極小ヒッティングセット (MHS) と呼ぶ. なお, サイズ最小のヒッティングセット (最小ヒッティングセット: Minimum Hitting Set, MinHS) を求める問題は NP 困難 (NP-hard) であることが知られている [3].

MHS 列挙問題の重要な応用の一つとして, 医療分野における薬物相互作用 (Drug-Drug Interaction: DDI) の解析が挙げられる. 副作用が報告された膨大な処方データから, その原因となる極小な薬の組み合わせを特定する問題は MHS 列挙問題に帰着され [4], 創薬や安全性監視 (Pharmacovigilance) の観点から高速なアルゴリズムが求められている [7].

しかし, 理論的に存在するすべての MHS を列挙することは, 解の個数が指数関数的になりうるため, 計算時間やメモリの制約上困難な場合が多い. また, 故障診断や副作用解析などの多くの応用において, 最終的に得られた解を検証するのは人間であるため, 要素数が少なく解釈が容易な解こそが実務上扱いやすく重要である. したがって, サイズ上限 k を設けた「サイズ制約付き極小ヒッティングセット (Min- k -MHS) 列挙」は, 人間が扱える範囲の重要な知見を効率的に得られるため, 実用上有用な定式化である.

1.2 課題

大規模データにおけるサイズ制約付き極小ヒッティングセット列挙 (k -MHS Enumeration) 問題の主要な課題は, 解空間の爆発的な広さにある. この問題に対処するため, 分枝限定法 (Branch-and-Bound) による枝刈りが不可欠であるが, 計算コストと枝刈り性能のトレードオフが大きな障壁となっている.

本来, 探索においては「サイズ制約」と「極小性制約」の双方が利用可能であるが, 探索の途中で極小性を厳密にチェックすることは計算コストが極めて高い. そこで一般的には, 「極小ヒッティングセットは, 必ずヒッティングセットの条件を満たす」という性質を利用し, 問題を緩和するアプローチが取られる. 具体的には, 最小ヒッティングセット (MinHS) 問題の双対問題である最大セットパッキング (MaxSP) を用いた下界計算 ($\nu(H) \leq \tau(H)$) を利用して枝刈りを行う [9].

しかし, 既存研究の多くは特定の近似アルゴリズムの提案や高速化に主眼を置いており, MaxSP による枝刈りそのものが持つ「理論的な限界性能」については十分に明らかにされていない. 具体的には, 探索ノード数の増加が, 双対ギャップ ($\tau(H) - \nu(H)$) に起因するのか, あるいは近似アルゴリズムの利用によるギャップ ($\nu(H) - \hat{\nu}(H)$) に起因するのかが判別できていない. この

要因が分離されていないため、現状の延長線上（近似精度の向上）に計算時間を削減できる余地がどの程度残されているのか、あるいは既に MaxSP 緩和の原理的な限界に達しているのかを判断できないという問題がある。

1.3 本研究の目的

本研究の目的は、もし仮に**最高性能のサイズ制約枝刈り関数**が実現された場合、**計算をどの程度まで削減できるのか**という、探索効率化の理想的な限界を見積もることである。

新たな高速化アルゴリズムを提案するのではなく、現在の MaxSP ベースのアプローチに**どれだけの改善の余地が残されているのか**を定量的に明らかにすることを狙いとする。そのために、以下の3つの水準の下界関数を定義し、それぞれの探索ノード数を比較検証することで、理想的な枝刈り性能に対する現実の解法の乖離を評価する。

1. **Oracle MinHS（神託的最小ヒッティングセット）** 最小ヒッティングセット問題の真の最適値 $\tau(H)$ を下界として用いるモデル。「理論上最も強力な（最高性能の）枝刈り」をシミュレートするものであり、計算時間の削減限界を見積もるためのベースライン（理想値）として導入する。
2. **Exact MaxSP（厳密最大セットパッキング）** 双対問題である MaxSP の厳密解 $\nu(H)$ を計算して下界とするモデル。Oracle MinHS との比較により、MinHS と MaxSP の間の双対ギャップ $(\tau(H) - \nu(H))$ が、理想的な枝刈りを阻害する要因としてどの程度影響するかを評価する。
3. **Greedy MaxSP（貪欲最大セットパッキング）** MaxSP の近似解 $\hat{\nu}(H)$ を高速な貪欲法で求める実用的なモデル。Exact MaxSP との比較により、近似アルゴリズムの利用によるギャップ $(\nu(H) - \hat{\nu}(H))$ が、探索効率にどの程度影響するかを評価する。

これら3つの下界値には常に $\hat{\nu}(H) \leq \nu(H) \leq \tau(H)$ の関係が成立する。本研究では、これらの比較実験を通じて、ハイパーグラフの構造が各ギャップに与える影響を明らかにし、今後のアルゴリズム開発における指針を与える。

1.4 論文の構成

本論文の構成は以下の通りである。第2章で問題定義と双対性の理論的基礎を述べ、第3章で数理モデルを定式化する。第4章で提案する分枝限定法と3つの下界計算手法を詳述し、第5章で計算実験による性能評価を行う。最後に第6章でまとめと今後の展望を述べる。

第2章 問題定義

本章では本研究の基礎となるハイパーグラフおよび関連する最適化問題について数式を用いて厳密に定義する。また、ヒッティングセット問題とセットパッキング問題の間に成立する弱双対定理について述べ、その数学的証明を与える。

2.1 基本記号とハイパーグラフ

2.1.1 ハイパーグラフの定義

ハイパーグラフ (Hypergraph) は頂点集合 V , ハイパーエッジ (以下, エッジ) 集合 E の組 $H = (V, E)$ として定義される。ここで各エッジ $e \in E$ は V の部分集合である ($e \subseteq V$) 。

通常のグラフにおけるエッジが常に2つの頂点を結ぶのに対し、ハイパーグラフのエッジは任意の数の頂点を含むことができる。

2.2 ヒッティングセット問題 (Hitting Set Problems)

2.2.1 ヒッティングセットの定義

頂点集合の部分集合 $S \subseteq V$ がヒッティングセット (Hitting Set) であるとはすべてのエッジ $e \in E$ と少なくとも一つの共通要素を持つことである。

定義 2.2.1 (ヒッティングセット)。

$$S \text{ はヒッティングセットである} \iff \forall e \in E, S \cap e \neq \emptyset \quad (2.1)$$

2.2.2 極小ヒッティングセットの定義

ヒッティングセット S が極小ヒッティングセット (Minimal Hitting Set: MHS) であるとは S の任意の真部分集合がヒッティングセットでないことである。

定義 2.2.2 (極小ヒッティングセット)。

$$S \text{ は極小ヒッティングセットである} \iff \begin{cases} S \text{ はヒッティングセットである} \\ \forall S' \subsetneq S, \exists e \in E \text{ s. t. } S' \cap e = \emptyset \end{cases} \quad (2.2)$$

すなわち, S からどの要素 v を除去しても e を被覆できなくなるようなエッジ e が存在する状態を指す。

2.2.3 最小ヒッティングセット問題

最小ヒッティングセット問題 (Minimum Hitting Set Problem: MinHS) はサイズ (要素数) が最小のヒッティングセットを求める問題である.

$$\tau(H) = \min\{|S| \mid S \subseteq V, \forall e \in E, S \cap e \neq \emptyset\} \quad (2.3)$$

ここで $\tau(H)$ はハイパーグラフ H の最小ヒッティングセット数 (Transversal Number) と呼ばれる. この問題は最小頂点被覆問題 (Minimum Vertex Cover) のハイパーグラフへの一般化に相当し NP 困難であることが知られている [3].

2.2.4 サイズ制約付き極小ヒッティングセット列挙

本研究ではサイズが k 以下のすべての極小ヒッティングセットを列挙する問題を扱う. これを本論文では「サイズ制約付き極小ヒッティングセット列挙問題 (k-MHS Enumeration Problem)」と呼ぶ.

入力 ハイパーグラフ $H = (V, E)$, サイズ上限 $k \in \mathbb{Z}^+$
出力 $\{S \mid S \text{ is a Minimal Hitting Set and } |S| \leq k\}$

2.3 セットパッキング問題 (Set Packing Problems)

2.3.1 セットパッキングの定義

エッジ集合の部分集合 $P \subseteq E$ が**セットパッキング (Set Packing)** であるとはそれに含まれる任意のエッジ対が互いに素 (disjoint) であることである.

定義 2.3.1 (セットパッキング).

$$P \text{ はセットパッキングである} \iff \forall e_i, e_j \in P (i \neq j), e_i \cap e_j = \emptyset \quad (2.4)$$

2.3.2 最大セットパッキング問題

最大セットパッキング問題 (Maximum Set Packing Problem: MaxSP) はサイズが最大のセットパッキングを求める問題である.

$$\nu(H) = \max\{|P| \mid P \subseteq E, \forall e_i, e_j \in P (i \neq j), e_i \cap e_j = \emptyset\} \quad (2.5)$$

ここで $\nu(H)$ はハイパーグラフ H の最大パッキング数 (Packing Number) と呼ばれる.

2.3.3 競合グラフによる定式化

最大セットパッキング問題の構造をより明確にするためハイパーグラフの**競合グラフ (Conflict Graph)** $G_{conf} = (V_c, E_c)$ を導入する.

定義 2.3.2 (競合グラフ).

ハイパーグラフ $H = (V, E)$ に対し以下の条件を満たすグラフ $G_{conf} = (V_c, E_c)$ を競合グラフ (Conflict Graph) と定義する.

1. 頂点集合 V_c はエッジ集合 E と等しい.

$$V_c = E \quad (2.6)$$

2. 辺集合 E_c は共通部分を持つエッジ対の集合とする.

$$\{e_i, e_j\} \in E_c \iff e_i \cap e_j \neq \emptyset \quad (i \neq j) \quad (2.7)$$

この定義の下では, ハイパーグラフ H 上のセットパッキング (互いに素なエッジ集合) は競合グラフ G_{conf} 上において互いに辺で結ばれていない頂点集合, すなわち**独立集合 (Independent Set)** と一対一に対応する. したがって, 最大セットパッキング問題 (MaxSP) は競合グラフ上の最大独立集合問題 (Maximum Independent Set Problem) と等価であり一般に NP 困難である [3].

2.4 双対関係と下界

2.4.1 弱双対定理

ヒッティングセット問題 (MinHS) とセットパッキング問題 (MaxSP) の間には「弱双対性 (Weak Duality)」が成立する.

定理 2.4.1 (弱双対定理).

任意のハイパーグラフ $H = (V, E)$ に対して以下の不等式が成立する.

$$\nu(H) \leq \tau(H) \quad (2.8)$$

すなわち, 最大パッキング数は最小ヒッティングセット数を超えない.

証明.

任意のパッキング $P \subseteq E$ と任意のヒッティングセット $S \subseteq V$ を考える.

パッキングの定義より任意の異なる $e_i, e_j \in P$ に対して $e_i \cap e_j = \emptyset$ である. 一方, ヒッティングセットの定義よりすべての $e \in P$ に対して $S \cap e \neq \emptyset$ である. したがって, 各エッジ $e \in P$ を被覆するためにはそれぞれ少なくとも 1 つの頂点が必要となる.

ここで, $e_i, e_j \in P$ ($i \neq j$) は共通部分を持たないためある頂点 v が e_i と e_j を同時に被覆することはできない. ゆえに, P に含まれる $|P|$ 個のエッジをすべて被覆するためには少なくとも $|P|$ 個の互いに異なる頂点が S に含まれていなければならない.

よって, 不等式 $|P| \leq |S|$ が成立する. これは任意の P, S について成り立つためそれぞれの最大値・最小値についても同様に成立する.

$$\nu(H) = \max_P |P| \leq \min_S |S| = \tau(H)$$

□

第3章 定式化

本章では前章で定義した問題を数理計画問題として厳密に定式化する。また、分枝限定法において探索空間を削減するための「枝刈り条件」および解の「極小性条件」の理論的根拠となる数式を導出する。

3.1 整数計画法による定式化

MinHS 問題および MaxSP 問題は整数計画問題 (Integer Programming: IP) として以下のよう記述できる。

3.1.1 MinHS の IP 定式化

各頂点 $j \in V$ に対して選択変数 $x_j \in \{0, 1\}$ を導入する。 $x_j = 1$ は頂点 j がヒッティングセットに含まれることを表す。 MinHS 問題は以下のように定式化される。

$$\text{(MinHS)} \quad \text{minimize} \quad \sum_{j=1}^n x_j \quad (3.1)$$

$$\text{subject to} \quad \sum_{j \in e_i} x_j \geq 1, \quad \forall e_i \in E \quad (3.2)$$

$$x_j \in \{0, 1\}, \quad \forall j \in V \quad (3.3)$$

制約式 (3.2) はすべてのエッジ e_i が少なくとも 1 つの頂点によって被覆されなければならない (ヒッティング制約) ことを表している。

3.1.2 MaxSP の IP 定式化

各エッジ $i \in \{1, \dots, m\}$ に対して選択変数 $y_i \in \{0, 1\}$ を導入する。 $y_i = 1$ はエッジ e_i がパッキングに含まれることを表す。 MinHS の双対問題に相当する MaxSP 問題は以下のように定式化される。

$$\text{(MaxSP)} \quad \text{maximize} \quad \sum_{i=1}^m y_i \quad (3.4)$$

$$\text{subject to} \quad \sum_{i: j \in e_i} y_i \leq 1, \quad \forall j \in V \quad (3.5)$$

$$y_i \in \{0, 1\}, \quad \forall e_i \in E \quad (3.6)$$

制約式 (3.5) は各頂点 j が最大でも 1 つのエッジにしか含まれてはならない (パッキング制約) ことを表している。

3.2 枝刈り条件の導出

分枝限定法における枝刈り (Pruning) の正当性を保証する論理式を導出する.

探索木の任意のノードにおいて既に選択された頂点集合を S_{cur} , まだ被覆されていないエッジ集合を $U \subseteq E$ とする. このノードから派生する任意の完全解 S は, S_{cur} に U を被覆するための追加頂点集合 S_{add} を加えたものとなる ($S = S_{cur} \cup S_{add}$).

ここで, S がサイズ上限 k 以下の実行可能解であるための必要条件を考える. 弱双対定理 (定理 2.4.1) より, 未被覆部分 U を被覆するために必要な最小頂点数 $\tau(U)$ はその部分問題に対する最大パッキング数 $\nu(U)$ 以上である.

$$|S_{add}| \geq \tau(U) \geq \nu(U) \quad (3.7)$$

したがって, 最終的な解のサイズ $|S|$ について以下の不等式が成立する.

$$|S| = |S_{cur}| + |S_{add}| \geq |S_{cur}| + \nu(U) \quad (3.8)$$

これより, 以下の条件が成立する場合そのノードの如何なる子孫においてもサイズ k 以下の解は存在しないことが論理的に帰結される.

$$|S_{cur}| + \nu(U) > k \quad (3.9)$$

本研究のアルゴリズムではこの式 (3.9) を枝刈りの判定式として用いる.

3.3 極小性の必要十分条件

求まったヒッティングセット S が「極小 (Minimal)」であるかどうかの判定基準を定義する.

定義 3.3.1 (必須頂点).

頂点 $v \in S$ が S において必須であるとは v を除去するとヒッティングセットの条件を満たさなくなることを, すなわち, v によってのみ被覆されているエッジが存在することを意味する.

$$v \text{ is critical for } S \iff \exists e \in E \text{ s. t. } e \cap S = \{v\} \quad (3.10)$$

極小ヒッティングセットの定義 (真部分集合が解とならない) より以下の定理が成り立つ.

定理 3.3.1 (極小性の判定 [1]).

ヒッティングセット S が極小であるための必要十分条件はすべての頂点 $v \in S$ が必須であることである.

$$S \in MHS \iff \forall v \in S, \exists e \in E \text{ s. t. } e \cap S = \{v\} \quad (3.11)$$

第4章 比較手法

本章では, 前章で導出した定式化および枝刈り条件に基づき, サイズ制約つき極小ヒッティングセット列挙を行う具体的なアルゴリズムについて述べる. また, 3 種類の下界計算戦略の疑似コードと, 極小性判定の高速実装, および計算量解析について述べる.

4.1 アルゴリズムの全体枠組み

提案手法は, 深さ優先探索 (DFS) に基づく分枝限定法である. 各探索ノードにおいて, 式 (3.9) に基づいた下界計算を行い, 解を含まないと判明した探索空間を切除する.

Algorithm 1 k-MHS Enumeration (Branch and Bound)

Require: Hypergraph $H = (V, E)$, Size limit k , Lower Bound Strategy $LB_Strategy$

Ensure: All minimal hitting sets S with $|S| \leq k$

- 1: $S \leftarrow \emptyset, U \leftarrow E$
 - 2: Initialize edge coverage counts
 - 3: RecursiveSearch(S, U)
-

Algorithm 2 RecursiveSearch(S, U)

Require: Current solution S , Uncovered edges U

```
1: if  $U = \emptyset$  then
2:   if  $S$  is minimal then
3:     Output  $S$ 
4:   end if
5:   return
6: end if
7: if  $|S| \geq k$  then
8:   return
9: end if
10:  $lower\_bound \leftarrow \text{CalculateLB}(U, LB\_Strategy)$ 
11: if  $|S| + lower\_bound > k$  then
12:   return
13: end if
14: Select an edge  $e \in U$  to branch on
15: for each vertex  $v \in e$  do
16:    $S_{new} \leftarrow S \cup \{v\}$ 
17:   Update edge coverage counts for  $v$ 
18:    $U_{new} \leftarrow \{e' \in U \mid v \notin e'\}$ 
19:   RecursiveSearch( $S_{new}, U_{new}$ )
20:   Restore edge coverage counts for  $v$ 
21: end for
```

4.2 下界計算戦略と疑似コード

Algorithm 1 内の CalculateLB 関数として, 本研究では以下の 3 つの戦略を比較・検証する.

4.2.1 Greedy MaxSP (貪欲法)

競合グラフ上の最大独立集合問題を, 次数最小戦略に基づく貪欲法で解く. 以降では Greedy と表記する.

Algorithm 3 CalculateLB: Greedy MaxSP

Require: Uncovered edges U **Ensure:** Lower bound value L

```
1: Construct conflict graph  $G_{conf}$  from  $U$ 
2:  $L \leftarrow 0$ 
3: while  $G_{conf}$  has vertices do
4:   Select vertex  $e \in V(G_{conf})$  with minimum degree
5:    $L \leftarrow L + 1$ 
6:   Remove  $e$  and all its neighbors from  $G_{conf}$ 
7: end while
8: return  $L$ 
```

4.2.2 Exact MaxSP (厳密解法)

競合グラフ上の最大独立集合問題 (MIS) を, 再帰的な分枝限定法を用いて厳密に解く. 以降では Exact と表記する.

Algorithm 4 CalculateLB: Exact MaxSP

Require: Uncovered edges U **Ensure:** Lower bound value L

- 1: Construct conflict graph G_{conf} from U
 - 2: **return** MaxIndependentSetSize(G_{conf})
-

Algorithm 5 MaxIndependentSetSize(G)

Require: Graph G **Ensure:** Maximum independent set size

- 1: **if** $V(G) = \emptyset$ **then**
 - 2: **return** 0
 - 3: **end if**
 - 4: Select a vertex $v \in V(G)$
 - 5: $size_exclude \leftarrow \text{MaxIndependentSetSize}(G - \{v\})$
 - 6: $size_include \leftarrow 1 + \text{MaxIndependentSetSize}(G - \{v\} - N(v))$
 - 7: **return** $\max(size_exclude, size_include)$
-

4.2.3 Oracle MinHS

理論的な比較のため, 主問題である MinHS を厳密に解き, その解 $\tau(U)$ を下界として用いる. 以降では Oracle と表記する.

Algorithm 6 CalculateLB: Oracle MinHS

Require: Uncovered edges U **Ensure:** Lower bound value L

- 1: **return** ExactMinHS(U)
-

4.3 極小性判定の実装

第 3 章で定義した「必須頂点」の条件を高速に判定するため各エッジの「被覆数 (Coverage Count)」を動的に管理する [5].

- **データ構造**

配列 $count[1 \dots m]$ を用意し $count[i]$ にエッジ e_i が現在の S に含まれる頂点によって何回被覆されているかを格納する.

- **更新**

探索が進み頂点 v を追加する際 v を含むすべてのエッジのカウンタを +1 する. バックトラック時は -1 する.

- 判定

S がヒッティングセットになった時点ですべての $v \in S$ について以下を確認する.

$$\text{IsCritical}(v) \iff \exists e \in E \text{ s. t. } v \in e \wedge \text{count}[e] = 1$$

この条件を満たすエッジが存在すれば v は必須である. 全ての $v \in S$ が必須であれば S は極小である.

4.4 計算量解析

各下界計算手法を用いた場合の 1 ノードあたりの計算量を比較する. ここで n は頂点数, m はエッジ数である.

表 4.1: 各手法の計算量比較

手法	計算量
Greedy MaxSP	$O(m^2)$
Exact MaxSP	$O(1.2^m)$
Oracle MinHS	$O(n^k)$

各手法の計算量の根拠は以下の通りである.

1. Greedy

まず, ハイパーグラフから競合グラフを構築するためにすべてのエッジ対の交差判定を行う必要があり $O(m^2 \cdot n)$ を要する. その後の貪欲法によるノード選択と削除は最大でもエッジ数 m 回の反復で完了し各ステップの更新コストを含めても $O(m^2)$ で収まる.

2. Exact

Greedy と同様, まず $O(m^2 \cdot n)$ をかけて競合グラフを構築する. その後, 頂点数 m の競合グラフに対して最大独立集合 (MIS) を厳密に求める. この処理は各頂点 (元のハイパーエッジ) について「解に採用するか否か」を決定する分岐操作を再帰的に行うため, 最悪ケースでは深さ m の探索木となり $O(2^m)$ の計算量を要する. なお, より高度な分岐ルールを用いたアルゴリズム [6] を適用したとしても, 理論的な計算量は $O(1.2108^m)$ 程度であり, 依然として指数時間を要することに変わりはない.

3. Oracle

サイズ k のヒッティングセットを単純に探索する場合最悪ケースでは n 個の頂点から k 個を選ぶすべての組み合わせを調べる必要がある. その組み合わせ数は $\binom{n}{k} \approx \frac{n^k}{k!}$ でありオーダー記法では $O(n^k)$ となる.

第5章 計算実験

本章では前章で定義した実験設定に基づき理論的ベースライン（Oracle）、厳密解法（Exact）、および近似解法（Greedy）の3つの手法間での探索ノード数を計測した結果について述べる.

5.1 実験環境

実験は表 5.1 に示す計算機環境下で実施した. すべてのアルゴリズムは C 言語で実装した.

表 5.1: 実験環境

項目	内容
CPU	AMD Ryzen 5 8640U (3. 50 GHz, 6 Cores / 12 Threads)
Memory	16 GB
Language	C

5.2 評価指標

下界精度の違いが探索効率に与える影響を評価するため以下の探索オーバーヘッドを定義する. 探索オーバーヘッドは 0%に近いほど枝刈りが効果的に機能していることを示す.

- **双対ギャップによる探索オーバーヘッド（以下, Dual と表記）**

理論的な最大パッキング数 $\nu(H)$ が最小ヒッティングセット数 $\tau(H)$ に届かないことに起因する探索ノード数の増加率.

$$\text{Overhead}_{\text{Dual}} = \frac{\text{Nodes}_{\text{Exact}} - \text{Nodes}_{\text{Oracle}}}{\text{Nodes}_{\text{Exact}}} \times 100(\%) \quad (5.1)$$

- **近似ギャップによる探索オーバーヘッド（以下, Approx と表記）**

貪欲法が厳密な最大パッキング数を求められないことに起因する探索ノード数の増加率.

$$\text{Overhead}_{\text{Approx}} = \frac{\text{Nodes}_{\text{Greedy}} - \text{Nodes}_{\text{Exact}}}{\text{Nodes}_{\text{Greedy}}} \times 100(\%) \quad (5.2)$$

5.3 構造指標の導入

本研究では以下の 3 つの構造指標を定義する.

- **ランク (Rank) r**

ハイパーグラフを構成する各エッジ (集合) に含まれる頂点数の最大値.

$$r(H) = \max_{e \in E} |e| \quad (5.3)$$

ランク r は個々のエッジが持つ頂点の占有数を表す局所的な指標である.

- **競合密度 (Conflict Density) ρ**

すべてのエッジ対の組み合わせに対する実際に交差しているペアの割合.

$$\rho = \frac{|E_{conf}|}{\binom{m}{2}} = \frac{2|E_{conf}|}{m(m-1)} \quad (5.4)$$

ここで $|E_{conf}|$ は交差グラフ上の辺の数である. ρ はランクやアスペクト比の結果として生じるエッジ間の排他構造の強度を表す.

- **アスペクト比 (Aspect Ratio) α**

頂点数 n に対するエッジ数 m の比率.

$$\alpha = \frac{m}{n} \quad (5.5)$$

アスペクト比 α はハイパーグラフ全体におけるエッジの密度を表す大域的な指標である.

5.4 実験結果

本章では, 前章で定義した 3 つの指標 (ランク r , アスペクト比 α , 競合密度 ρ) に基づき選定したインスタンスに対し, 3 つの下界関数を用いた際の探索ノード数を比較する.

「近似ギャップによる探索オーバーヘッド (Approx)」については全実験を通じて厳密解と近似解がほぼ一致する (オーバーヘッドが 0% に近い) 結果が得られたため, 本章の末尾 (5.9 節) にて一括して総括する.

5.5 実験 1. 射影平面グラフ (Projective)

5.5.1 概要

高い対称性と競合密度を持つ射影平面グラフの代表例として Fano Plane ($n = 7, m = 7$) を取り上げる. 射影平面は任意の 2 つのエッジが 1 つの頂点を共有し, かつ任意の 2 つの頂点が 1 つのエッジに含まれるという規則性を持つ.

- $r = 3, \quad \alpha = 1.0, \quad \rho \approx 0.90$
- 任意の 2 エッジが必ず交差するためパッキングが大きくなりにくい構造を持つ.

5.5.2 結果

表 5.2 に探索ノード数および Dual を示す.

$k = 2$ において $\rho \approx 0.9$ という競合密度が大きい構造においては, MaxSP 緩和が機能せず大きなオーバーヘッドが発生することが確認された.

表 5.2: Fano Plane ($n = 7, m = 7$) における探索ノード数と探索オーバーヘッドの評価

Size k	Nodes			Overhead (%)
	Greedy	Exact	Oracle	Dual
1	1	1	1	0. 0
2	13	13	1	92. 3
3	33	33	30	9. 1
4	50	50	50	0. 0

5.6 実験 2. 2部グラフ (Bipartite)

5.6.1 概要

完全 2 部グラフ $K_{10,10}$ ($n = 20, m = 10$) を用いる.

- $r = 10$, $\alpha = 0.5$, $\rho = 1.00$
- すべてのエッジが互いに交差する完全競合状態にある.

5.6.2 結果

表 5.3 に結果を示す.

表 5.3: 完全 2 部グラフ $K_{10,10}$ ($n = 20, m = 10$) における探索ノード数と探索オーバーヘッドの評価

Size k	Nodes			Overhead (%)
	Greedy	Exact	Oracle	Dual
1	12	12	12	0. 0
2	23	23	23	0. 0
5	56	56	56	0. 0
10	111	111	111	0. 0

競合密度が最大 ($\rho = 1.0$) であっても Dual は 0. 0%であった. これは実験 1 の結果と対照的である. この結果は競合密度だけでは MaSP による枝刈りの効果を説明しきれないことを示唆しており, グラフが持つ規則性も影響していることを示している.

5.7 実験 3 実データとその補集合データ (Actual)

5.7.1 概要

実データ `ac_200k` と, その補集合データ `ac_200k_c` を比較する. 補集合データとは, 各エッジをその補集合 $\bar{e} = V \setminus e$ に置き換えたものである. これにより, アスペクト比 α を保ったままリンク r や競合密度 ρ を変化させることができる.

なお, このデータセットはベルギーにおける交通事故の記録を集計したものでありハイパーグラフとしての構成は以下の通りである. 頂点は事故に関連する属性 (例: 「天候=雨」「場所=交差

点」「深刻度＝軽傷」など）に対応し、エッジは 1 件ごとの交通事故記録に対応する。1 件の事故には多数の属性が付与されるため、このデータは平均して大きなエッジサイズを持つ傾向がある。

- **実データ** $r \approx 57.5$, $\alpha \approx 1.27$
- **補集合データ** $r \approx 6.5$, $\alpha \approx 1.27$

5.7.2 結果

表 5.4 に結果を示す。

表 5.4: 実データと補集合データにおける探索ノード数と探索オーバーヘッドの評価

Setting	k	Greedy	Exact	Oracle	Dual(%)
Original ($r \approx 57.5$)	1	57	57	57	0. 0
	5	2497	2497	2497	0. 0
	20	2530	2530	2530	0. 0
Complement ($r \approx 6.5$)	1	9	9	1	88. 9
	2	35	35	25	28. 6
	5	213	213	199	6. 6

両者は同一のアスペクト比 $\alpha \approx 1.27$ を持つにも関わらず結果が極端に異なった。アスペクト比だけでは探索オーバーヘッドを予測するには不十分であることが明らかになった。

5.8 実験 4. ランダムグラフにおけるランク分散と競合密度の影響

5.8.1 実験の目的と設計

前節までを踏まえ、ランクと競合密度の影響を検討するため以下の設定によってランダムに生成したグラフで実験を行う。

実験設定

- 頂点数 $n = 20$ 固定, エッジ数 $m \in \{5, 10, 15, \dots, 40\}$.
- ランクパラメータ $r \in \{2, 3, 4, \dots, 20\}$ (計 19 水準).
- 各エッジのサイズを 2 から r の一様分布 $U[2, r]$ で決定する.

この設定の下で 740 のインスタンスを生成し、実験を行った。

5.8.2 ランクと探索オーバーヘッドの関係

図 5.1 に、ランクパラメータ r と探索オーバーヘッド (Dual) の関係を示す。赤線は LOWESS 平滑化曲線 [2] による傾向を表している。

なお、LOWESS 平滑化曲線とはデータの局所的な部分集合に対して重み付き回帰を行うことで得られる曲線である。本実験の結果は単純な線形回帰では捉えきれない非線形な挙動を持っているため、その大局的な傾向を可視化する目的で本手法を採用した。




図 5.1: ランクと探索オーバーヘッド最大値の関係

この結果から、ランク r と探索オーバーヘッドの関係は単調増加ではなく、以下の 3 つのフェーズがあると考えられる。

1. $r = 2$ から 8 にかけて探索オーバーヘッドは上昇し約 60% に達する。これはエッジの平均サイズが中程度で分散が比較的小さい領域であり、MinHS と MaxSP の双対ギャップが最も開きやすい状態であるためだと考えられる。
2. r が 10 を超えると、一時的に探索オーバーヘッドは 10% 程度まで低下する。これは分散 σ^2 の増大により、グラフ内に「パッキングしやすい極小エッジ」と「被覆しやすい巨大エッジ」が MinHS と MaxSP の双対ギャップが小さくなったためだと考えられる。（ランクパラメータ r を大きくすることは、エッジサイズの分散の拡大も意味する。理論的なサイズ分布の母分散は r に対して二次関数的に増加する。）
3. r が 20 に近づくと再びオーバーヘッドが増加する。巨大なエッジが乱立することで競合密度が限界 ($\rho \approx 1.0$) に達し、グラフがランダムな完全グラフ（クリーク）に近い状態となるためだと考えられる。

5.8.3 競合密度の影響

図 5.2 に, 競合密度 ρ と探索オーバーヘッドの関係を示す. 赤線は LOWESS 平滑化曲線による傾向を表している.




図 5.2: 競合密度と探索オーバーヘッド最大値の関係

若干ではあるがこの結果から, 競合密度 ρ が高いほど探索オーバーヘッドの増加傾向が読み取れる.

5.9 カテゴリ別検証のまとめ

以上の実験結果より, 本研究に対して以下の知見が得られた.

1. 全実験を通じて Greedy と Exact の差は僅少であり, 近似アルゴリズムの改善余地は少ない.
2. MaxSP 緩和による枝刈り効果の傾向は以下のように考えられる.
 - 中途半端なエッジサイズで分散が小さい場合 (中ランクの壁), または競合密度が極限まで高い場合は枝刈りの効果は強い.
 - 規則性がある場合 (2 部グラフ), またはエッジサイズの分散が大きく構造的な手がかりが豊富な場合は枝刈りの効果は弱い.

第6章 考察とまとめ

本章では第5章で得られた実験結果に基づき本研究の主目的である「最大セットパッキング (MaxSP) に基づく下界関数の性能評価」について総括する。探索ノード数の増大要因を「近似アルゴリズムの精度 (近似ギャップ)」と「数理的な構造上の限界 (双対ギャップ)」の2点に分解して分析し、ソルバ開発に向けた指針を検討する。

6.1 実験結果の考察

比較実験において観測された「探索オーバーヘッド」の挙動から以下の2つの主知見が得られた。

6.1.1 近似ギャップの影響と貪欲法の有効性

全ての実験を通じて近似ギャップによる探索オーバーヘッドは0%, もしくは極めて微小な値にとどまることが確認された。

$$\text{Nodes}_{\text{Greedy}} \approx \text{Nodes}_{\text{Exact}} \quad (6.1)$$

一部の高い競合密度を持つランダムグラフや特定の構造を持つインスタンスにおいて、貪欲法が局所解に陥り厳密解法を用いた場合よりも探索ノード数が増加する ($\text{Overhead}_{\text{Approx}} > 0$) ケースが観測された。しかしながら、観測されたノード数の増加率は厳密解法の計算時間が指数時間であることと比較すれば許容範囲内であるといえる。すなわち、計算量を考慮すれば探索ノードの増加を許容してでも貪欲法を採用する方が有利である。

6.1.2 グラフ構造と双対ギャップの関係

Actual インスタンスにおいて、アスペクト比が同一であるにもかかわらずランク r の違いによってオーバーヘッドは0% から約90% まで激しく変動した。これはMaxSP 下界の精度を決定づけるのはアスペクト比ではなくランクと競合密度であることを示唆している。したがって以下ではランクと競合密度の組み合わせに着目して考察する。

1. ランクの影響

本研究の可変ランク実験により、ランクパラメータ r と探索オーバーヘッドは以下のような関係性を持つことが確認された。

• 中ランクの壁

ランクが頂点数に対して中途半端に大きく、かつ分散が小さい領域では、パッキングと被覆が乖離し、探索オーバーヘッドが大きくなる。

- **分散による緩和**

ランクがさらに増加するとエッジサイズの分散 (σ^2) も増大する. これによりグラフ内に「パッキングに有利な小さなエッジ」と「被覆に有利な大きなエッジ」が混在しやすくなり, 探索オーバーヘッドが小さくなる.

- 2. **競合密度の飽和**

ランクがさらに増大し頂点数 n に接近すると, 巨大なエッジが乱立することで競合密度が限界 ($\rho \approx 1.0$) に達する. この状態では競合グラフが完全グラフ (クリーク) に近づき, MaxSP 下界が「1」に張り付く. 一方で, 理論的ベースライン (Oracle) は大きな値をとり続ける. これにより, MaxSP 緩和は事実上機能を失い, 探索オーバーヘッドが大きくなる.

6.2 結論

本研究では最大セットパッキング (MaxSP) に基づく下界関数の性能を定量的に評価した. Oracle MinHS, Exact MaxSP, Greedy MaxSP の比較実験を通じて得られた結論は以下の通りである.

1. グラフが小規模である限り MaxSP 下界の実装において計算コストのかかる厳密解法を用いる必要性は低い. 単純な貪欲法であっても実用上十分な枝刈り性能が得られることが確認された.
2. MaxSP 緩和の有効性は, 「ランクおよびエッジサイズの分散」と「競合密度」のバランスに依存すると考えられる. 疎なグラフ, 規則的なグラフ (2 部グラフ等), あるいはエッジサイズの分散が大きく構造的な手がかりが豊富な領域では MaxSP 下界は高い枝刈り性能を発揮する. 一方で, 中ランク帯で分散が小さい領域, および巨大エッジにより密度が飽和している領域では双対ギャップが増加し, MaxSP ベースの手法だけでは探索空間を十分に削減できない.

6.3 今後の展望

本研究により MaxSP 緩和に基づくアプローチには高ランク・高競合密度のインスタンスにおいて性能劣化が存在することが確認された. これらのインスタンスに対してさらなる高速化を図るためには MaxSP よりも強力な下界関数の導入が必要である.

加えて, 本研究では下界性能の要因分析に重点を置いたため実験には比較的小規模から中規模のインスタンスを使用した. しかし, 実社会における応用場面では数万から数百万のエッジを持つ大規模なハイパーグラフを扱う必要性が生じる可能性がある. そのため, より大規模なデータセットを用いた検証も今後の課題として挙げられる.

謝辞

本研究の遂行にあたり、熱心な指導と助言を頂きました栗田和宏先生、柳浦睦憲教授に深く感謝の意を表します。日々の研究室生活においては柳浦研究室の皆様にお世話になりました。皆様のおかげで有意義な研究活動に勤しむことができました。深くお礼申し上げます。

参考文献

- [1] Claude Berge. *Hypergraphs: Combinatorics of Finite Sets*. North-Holland, 1984.
- [2] William S Cleveland. Robust locally weighted regression and smoothing scatterplots. *Journal of the American Statistical Association*, Vol. 74, No. 368, pp. 829–836, 1979.
- [3] Michael R. Garey and David S. Johnson. *Computers and Intractability: A Guide to the Theory of NP-Completeness*. W. H. Freeman, 1979.
- [4] Deirdre Walshe Molloy, Shirley A. Becker, and Bernhard Ø. Palsson. Optimal single drug intervention for treatment of suspected drug-drug interaction. *BMC Systems Biology*, Vol. 3, No. 1, pp. 1–9, 2009.
- [5] Keisuke Murakami and Takeaki Uno. Efficient algorithms for dualizing large-scale hypergraphs. *Discrete Applied Mathematics*, Vol. 170, pp. 83–94, 2014.
- [6] John Michael Robson. Algorithms for maximum independent sets. *Journal of Algorithms*, Vol. 7, No. 3, pp. 425–440, 1986.
- [7] Nicholas P. Tatonetti, Patrick P. Ye, Roxana Daneshjou, and Russ B. Altman. Data-driven prediction of drug effects and interactions. *Science Translational Medicine*, Vol. 4, No. 125, pp. 125ra31–125ra31, 2012.
- [8] Takeaki Uno and Mutsunori Yagiura. Fast algorithms for enumerating all common intervals of two permutations. In *Algorithms and Computation*, pp. 270–281. Springer, 2003.
- [9] Vijay V. Vazirani. *Approximation Algorithms*. Springer, 2001.